

발표 자료 구성안

계약서 돋보기 (Contract Lens) · 최지수 · 2026.10.12 발표

이 발표의 한 문장

정확도 93%인 줄 알았는데 실제로는 27%였다. 그래서 기능을 뺐다.

보통 발표는 "정확도 93% 달성"으로 간다. 이 발표는 반대로 간다. 성능을 올린 이야기가 아니라 성능을 정확히 알게 된 이야기다.

평가 기준 35%가 "결과 신뢰성 — AI 오류·불확실성 검증"이므로, 이 이야기가 곧 최고 배점 항목에 대한 답이 된다. 실패를 감추면 오히려 그 항목을 잃는다.

슬라이드 구성 (15장 · 13~16분 기준)

시간이 더 짧으면 9·10·12번을 줄이고, 길면 시연을 늘린다. 13번은 30초짜리라 통째로 빼도 흐름이 끊기지 않는다.

1. 표지 — 30초

계약서 돋보기 / Contract Lens

약관 조항에 관련 법 조문을 나란히 놓습니다

동아AI랩 3기 3차 프로젝트 · 최지수

말할 것: 이름 그대로다. 돋보기는 크게 보여줄 뿐 판단하지 않는다.

2. 문제 — 1분

넣을 것: 실제 약관 스크린샷 한 장. 조항이 뻑뻑한 화면.

말할 것: 계약서를 받으면 조항이 서른 개다. 법을 모르면 어디를 봐야 할지조차 모른다. 필요한 건 "이 계약 불공정합니다" 같은 판정이 아니라 어디를 볼지에 대한 실마리다.

3. 그래서 하지 않기로 한 것 — 1분 30초

넣을 것: 세 줄을 크게.

불공정 여부를 판정하지 않습니다
무효인지 말하지 않습니다
점수나 등급을 매기지 않습니다

말할 것: 두 가지 이유다. **법적으로** 변호사법 제109조가 비변호사의 법률사무를 금지한다. **실질적으로** 틀렸을 때 책임질 수 없다. 그래서 프로젝트 우선순위를 이렇게 정하고 시작했다 — 1) 정확성과 신뢰성, 2) 틀렸을 때 피해를 통제하는 구조, 3) 수익모델, 4) 그다음이 기술 난도.

여기가 이 발표 전체의 전제다. 뒤의 모든 결정이 여기서 나온다.

4. 시연 — 2분

넣을 것: 실제 화면. 미리 켜 두고 넘어가서 직접 조작.

보여줄 순서 0. **계약서 사진 올리기** — 글자를 읽어 편집창에 넣는다. 조항 몇 개를 찾았는지 알려 준다 1. 읽은 글자를 확인하고 고친 뒤 대조 (또는 실제 약관 붙여넣기) 2. 조항별 결과 — 원문과 조문이 **좌우로 나란히** 3. 후보를 눌러 조문 원문 펼치기 — 각 호와 효력, 쉬운 안내, 용어 풀이 4. 목적 조항은 "대조하지 않음" — 왜 건너뛰는지 밝힌다

사진 단계에서 한마디 덧붙인다: 읽은 글자를 바로 대조에 넘기지 않는다. OCR이 틀리면 조항 내용 자체가 바뀌므로 사람이 먼저 확인해야 한다.

말할 것: 화면에 빨간색이 없다. 경고 아이콘도 없다. 의도적이다. **시각 언어가 텍스트보다 강해서**, 고지에 "판정하지 않습니다"라고 아무리 써도 화면이 빨개지면 사용자는 판정으로 받아들인다.

5. 데이터 — 1분

데이터	규모
약관규제법 불공정 유형	28개
조문 전문	33개 조 / 105문장
판례	463건
표준약관	39건

말할 것: 전부 법제처 API로 직접 수집했다. 수집하면서 **API의 조문 필터를 믿으면 안 된다는** 걸 알았다. **J0=제7조** 로 받은 229건의 실제 참조조문에 제7조가 없었다. 그래서 본문을 직접 파싱하는 방식으로 바꿨다.

6. 구조 — 1분 30초

넣을 것: 플로우차트(설명문서 5.1의 그림).

말할 것: LangGraph로 조항별 fan-out. 조항끼리 의존이 없으니 갈라서 처리하고 리듀서로 합친다. 임베딩 모델은 실측으로 골랐다 — ko-sroberta가 e5보다 관련·무관 **간격이 14배** 넓었다(0.0186 대 0.2613).

7. 첫 성능 — 1분 ★여기까지가 보통의 발표

넣을 것: 큰 숫자.

표준약관 85개 기준	
Top-3	94.5%
'높음' 정확도	97.9%

말할 것: 여기서 끝냈다면 "정확도 97.9%"라고 발표했을 것이다.

(잠깐 멈춘다)

8. 그런데 — 2분 ★전환점. 이 발표의 핵심

넣을 것: 대비를 크게.

표준약관 (심사를 거친 문서)	97.9%
실제 사설 약관 (분쟁이 된 문서)	25%

말할 것: 평가 세트가 전부 **표준약관**이었다. 표준약관은 공정거래위원회 심사를 거친 문서라 애초에 깨끗하다. 실사용은 그런 문서가 아니다.

그래서 **판례에 인용된 실제 사설 약관 조항 49개**로 평가 세트를 새로 만들었다. 직접 라벨링했다. 결과가 위와 같다.

이 세트를 만들지 않았다면 몰랐을 것이다.

9. 고치려 한 네 갈래 — 2분

시도	결과
법 조문 오염 제거	26.3% → 31.2%. 필요했지만 원인이 아니었다
점수 분포의 모양	관련있음과 관련없음이 통계적으로 같다
LLM 관련성 게이트	50%까지 올렸으나 관련 조항 8개 중 6개를 잃는다
조문별 신뢰도	v2에서 90.9%로 좋아졌으나 v3에서 22.7%. 과적합

말할 것: 마지막 것이 특히 그렇다. 규칙을 만든 데이터에서만 좋아졌다. 독립 세트로 검증하지 않았다면 "개선했다"고 발표했을 것이다.

전부 실패했다. 조정의 문제가 아니라 방법의 한계다.

10. 그래서 기능을 뺐다 — 1분 30초

넣을 것: 전후 비교.

전: [높음] 약관규제법 제7조
후: 후보 1 약관규제법 제7조

말할 것: '높음'이라 써놓고 실제로 맞을 확률이 25%면 그 표시는 사용자를 속이는 것이다. 확신도를 표시하려면 그 확신에 근거가 있어야 하는데 없었다.

그래서 등급을 없애고 순위만 준다. 그리고 고지에 실측 정확도를 그대로 적었다.

1순위가 정답이라는 뜻이 아닙니다 (실측: 1순위 41.7%, 3개 안에 75.0%)

이건 후퇴가 아니라 "판정하지 않는다"는 원칙을 확신도 표시에까지 적용한 것이다.

11. 지금 성과와 한계 — 1분 30초

순위 매기기	Top-3 75.0%	실제 계약서에서도 쓸 만하다
판별력	27.0%	관련 없는 조항에도 후보가 붙는다

말할 것: 둘을 나눠서 봐야 한다. 찾는 일은 되고, 걸러내는 일은 안 된다. 표본도 작다(41~85개). 그래서 수치에 신뢰구간을 함께 적었다.

제7~14조만 다루는데, 정작 실제 분쟁은 제3·5·6조에서 많이 일어난다. 정식 배포도 못 했다 — 카드 없이 649MB를 무료로 주는 곳이 없었다.

12. 실제로 써보고서야 안 것 — 1분

증상	원인
조항 0개	조 제목과 본문이 다른 줄에 있는 형식
조문이 세로로 놓임	좁은 칸에 넣어 한 글자씩 줄바꿈
목적 조항이 1순위	어느 약관에나 있고 늘 비슷하게 쓰인다

말할 것: 셋 다 로컬 테스트로는 못 찾았다. **실제 약관을 넣어보고서야 알았다.** 고친 것마다 회귀 테스트를 남겨서 다시 깨지면 잡히게 했다.

13. 같은 함정에 세 번 — 30초

넣을 것: 세 쌍을 나란히.

표준약관 97.9%	실제 사설 약관 27.0%
짧은 문장 3개 "동일"	긴 조항에서 Top-1 이 달랐다
깨끗한 캡처 99.6%	실제 사진 16.8%

말할 것: 마지막 것은 발표 한 달 전에 사진 입력을 붙이면서 겪었다. 깨끗한 화면 캡처로 재니 99.6%가 나왔는데, 거기서 멈췄다면 또 같은 발표를 했을 것이다. **세 번째는 발표 전에 스스로 잡았다.** 다만 아직 실제 종이를 찍은 사진으로는 재지 않았으니 같은 실수가 한 번 더 남아 있다.

14. 배운 것 — 1분

측정 대상을 잘못 고르면 아무리 정교하게 재도 소용없다
쉬운 표본으로 잰 수치는 실사용을 대표하지 않는다
검증 조건은 실제 사용 조건과 같아야 한다
전체 평균은 정작 필요한 것을 가린다
성능을 못 올리면 약속을 바꾼다

말할 것: 마지막 줄이 이 프로젝트의 결론이다. 확신도를 표시할 근거가 없으면 **표시를 없애는 것이** 사용자에게 정직하다.

15. 마무리 — 30초

계약서 돋보기 / Contract Lens
돋보기는 크게 보여줄 뿐 판단하지 않습니다

파이썬 33개 파일 4,370줄 · 테스트 10개 · 커밋 50개 남짓
(발표 직전에 ``git rev-list --count HEAD`` 로 다시 셀 것)

준비물 확인

항목	상태
시연용 서버	<code>.\서비스_켜기.ps1</code> 로 미리 켜 둔다. 첫 요청이 10초 걸리므로 발표 전에 한 번 눌러 깨워 둔다
시연용 약관	실제 약관 하나를 미리 준비. 조항 0개가 나오던 형식이면 더 좋다
화면	결과 화면을 미리 한 번 띄워 두면 실패 위험이 없다
백업	인터넷이 끊길 때를 대비해 결과 화면 스크린샷을 슬라이드에 넣어 둔다

예상 질문과 답

"정확도가 27%면 쓸 수 있나요?" 순위 매기기는 Top-3 75%로 쓸 만하다. 걸러내는 능력이 27%다. 그래서 확신도를 표시하지 않고 "이 셋 중에 있을 가능성이 높다"까지만 말한다. 판단은 사용자가 한다.

"왜 LLM으로 판정하지 않았나요?" 변호사법 문제가 하나이고, 실제로 시켜 봤더니 못 한다는 게 둘이다. LLM 게이트를 붙였을 때 정확도는 올랐지만 관련 조항 8개 중 6개를 잃었다. "이 조항이 제7조에 해당하는가"는 변호사도 다투는 판단이다.

"실패한 이야기를 왜 이렇게 많이 넣었나요?" 평가 기준 35%가 "AI 오류·불확실성 검증"이다. 그리고 이 프로젝트의 우선순위 1번이 정확성과 신뢰성이었다. 실패를 감추면 그 두 가지를 모두 잃는다.

"사진 인식은 얼마나 정확한가요?" 조건에 따라 완전히 갈린다. 밝은 곳에서 정면으로 찍으면 95%인데 어둡고 기울면 17%로 떨어진다. 그래서 정확도를 말하는 대신 **조 번호를 몇 개 찾았는지**를 보여주고, 읽은 글자를 반드시 사람이 확인하게 한다. 본문이 틀린 것은 원본을 모르므로 원리적으로 잡을 수 없다.

"왜 배포를 못 했나요?" 임베딩 모델 때문에 실행 메모리가 649MB인데, 무료 티어는 대개 512MB다. ONNX로 711MB에서 272MB까지 줄였으나 배포 환경 기준으로는 여전히 초과였다. int8 양자화까지 해봤지만 Top-1이 70.9%에서 58.2%로 떨어져 쓰지 않았다. **정확도를 팔아 배포를 사는 거래는 이 프로젝트의 우선순위에 어긋난다.** 지금은 Cloudflare 터널로 공개한다.