

# 계약서 돋보기 (Contract Lens)

약관 조항에 관련 법 조문을 나란히 놓는 도구

동아AI랩 3기 3차 프로젝트 · 최지수 · 2026.08

## 1. 한 줄 요약

계약서나 약관을 붙여넣으면 조항마다 관련 있어 보이는 「약관의 규제에 관한 법률」 조문을 찾아 나란히 보여 준다. 불공정 여부는 판정하지 않는다.

## 2. 왜 만들었나

계약서를 받았는데 법을 모르는 사람은 어디를 봐야 할지조차 모른다. 조항이 서른 개인데 그중 무엇이 문제가 될 수 있는지 판단할 기준이 없다.

이때 필요한 것은 "이 계약은 불공정합니다" 같은 판정이 아니다. "제7조가 면책조항 규정과 관련 있어 보이니 그 조문을 읽어 보라"는 실마리다. 읽고 판단하는 것은 본인, 다투게 되면 변호사의 몫이다.

### 판정하지 않기로 한 이유

두 가지다.

**법적으로**, 변호사법 제109조는 비변호사의 법률사무 취급을 금지한다. 조문을 찾아 제시하는 것과 "이 조항은 무효입니다"라고 말하는 것은 다른 일이다.

**실질적으로**, 틀렸을 때 피해가 크다. "무효입니다"를 믿고 계약을 거절했는데 틀렸다면 책임질 수 없다. 이 프로젝트의 우선순위를 처음에 이렇게 정했다.

1. 결과의 정확성과 신뢰성
2. 틀렸을 때 발생할 피해와 그 위험을 통제하는 구조
3. 실제 지불 의사가 있는 수익모델
4. 그다음이 기술 난도, 기능 수, 화려함

이 문서의 4장 전체가 1번과 2번에 관한 것이다.

## 3. 데이터

전부 공개 데이터를 API로 직접 수집했다. 출처는 **법제처 국가법령정보 공동활용**이다.

| 데이터          | 규모            | 쓰임                            |
|--------------|---------------|-------------------------------|
| 약관규제법 불공정 유형 | 28개 (제6~14조)  | 대조 대상. 실제 매칭에는 제7~14조 24개를 쓴다 |
| 약관규제법 조문 전문  | 33개 조 / 105문장 | 조문 원문 보기                      |
| 판례           | 463건          | 평가 세트 v3 (실제 사설 약관 조항 추출)     |
| 표준약관(행정규칙)   | 39건           | 평가 세트 v2                      |

수집 과정에서 확인한 것

**API의 조문 필터를 믿으면 안 된다.** J0=제7조 로 받은 판례 229건의 실제 참조조문에 제7조가 없었다. 전체 463건 중 제7조를 참조한 것은 19건뿐이었다. 그래서 색인을 **본문의 참조조문을 직접 파싱하는 방식**으로 바꿨다.

**참조조문 표기가 4종으로 섞여 있다.** 띄어쓴 것 384건, 안 띄운 것 304건. 띄어쓴 것만 잡는 정규식으로는 304건을 놓친다. 공백을 지우고 매칭해야 한다.

**제7~14조는 판례가 거의 없다.** 실제 분쟁은 제3조(설명 의무)·제5조(해석)·제6조(일반원칙) 에서 일어난다 (제6조 138건, 제5조 108건, 제3조 106건 대 제7조 19건). 이 사실이 나중에 평가 세트를 설계할 때 결정적으로 작용했다.

4. 결과 신뢰성 — 이 프로젝트의 중심

성능을 올린 이야기가 아니라 **성능을 정확히 알게 된 이야기**다.

4.1 평가 세트를 세 번 만들었다

**v1은 실패했다.** "이 조항이 불공정한가"를 물었는데 **양성 표본이 0개**였다. 판례에서 인용한 문구는 조항 전체가 아니라 쟁점의 파편이라 맥락 없이는 판단할 수 없었다. 보류 21개가 전부 그 표본에 몰린 것이 증거였다.

근본 원인은 **이 서비스가 애초에 불공정 판정을 하지 않는다는** 것이었다. 하는 일이 관련 조문을 나란히 놓는 것이므로, 재야 할 것도 그것이어야 했다.

**v2는 태스크를 바꿨다.** "이 조항이 어느 조문과 관련되는가"로 묻자 측정이 됐다. 표준약관에서 조항 92개를 층화 추출해 직접 라벨링했다.

**v3는 실제 사설 약관으로 만들었다.** v2가 전부 표준약관이라 실사용을 대표하지 못한다고 보고, 판례에 인용된 조항 49개를 추출했다. 실제로 분쟁이 된 사설 계약서다.

4.2 측정 결과

|                  | v2 (표준약관 85개) | v3 (사실 약관 41개) |
|------------------|---------------|----------------|
| Top-1 (1순위가 정답)  | 70.9%         | 41.7%          |
| Top-3 (3개 안에 정답) | 94.5%         | 75.0%          |
| 보여준 것 중 실제 관련    | 93.1%         | <b>27.0%</b>   |

두 세트는 조건이 다르다. v2는 표준약관이라 조 제목이 있고, v3는 판례 인용이라 제목이 없다. 제목은 성능에 크게 기여하므로(v2도 제목을 빼면 Top-1 70.9% → 56.4%) 두 수치를 그대로 빼서 비교하면 안 된다. v3에 LLM으로 제목을 지어 붙여 재봤을 때는 Top-1 50.0% / Top-3 83.3%로 올랐으나 **판별력은 27.0% 그대로였다.**

그래서 이렇게 말하는 것이 정확하다. 순위 매기기는 실제 계약서에서도 쓸 만하고, 관련 없는 것을 걸러내는 능력은 표준약관에서만 좋아 보였다.

v3를 만들지 않았다면 "정확도 93%"라고 발표했을 것이다.

4.3 확신도 표시를 없앴다

처음에는 '높음/참고' 두 등급을 붙였다. 표준약관에서 '높음'의 정확도가 97.9%였다.

그런데 실제 사실 약관에서 재보니 25%였다. 판별력을 만들려고 네 갈래를 시도했고 전부 실패했다.

| 시도               | 결과                                    |
|------------------|---------------------------------------|
| 법 조문 오염 제거       | 26.3% → 31.2%. 필요했지만 원인이 아니었다         |
| 점수 분포의 모양(격차·분산) | 관련있음과 관련없음이 통계적으로 같다. 갈리지 않는다         |
| LLM 관련성 게이트      | 정확도 50%까지 올렸으나 관련 조항 8개 중 6개를 잃는다     |
| 조문별 신뢰도          | v2에서 90.9%로 좋아졌으나 v3에서 22.7%로 악화. 과적합 |

'높음'이라 써놓고 실제로 맞을 확률이 25%면 그 표시는 사용자를 속이는 것이다. 그래서 등급을 없애고 관련도 순위만 준다. 고지 문구에 실측 정확도를 그대로 밝힌다.

순서는 관련 가능성 추정이며 1순위가 정답이라는 뜻이 아닙니다 (실측 정확도: 1순위 41.7%, 3개 안에 포함 75.0%).

이것은 기능 후퇴가 아니라 "판정하지 않는다"는 원칙을 확신도 표시에까지 적용한 것이다.

4.4 진단이 틀렸던 것을 두 번 정정했다

첫 번째. "임베딩이 내용이 아니라 문체를 잴다"고 진단하며 두 문장을 비교했는데, 그중 하나가 문체가 다른 문장이 아니라 법 조문 원문 그 자체였다. 인덱스에 있는 문장을 쿼리로 넣었으니 높게 나오는 것이

당연했다. 문체만 바꾼 대조군 55개를 만들어 반증했다 (Top-3 94.5% → 96.4%, 사실상 차이 없음).

**두 번째.** ONNX 변환 후 짧은 문장 3개로 "유사도 1.000000, 완전히 동일"이라고 판단했는데, 평가 세트에서는 Top-1이 달랐다. 원인은 **자르는 길이**였다(sentence-transformers는 128, 내 코드는 512). 128로 맞추니 유사도 최저 0.9999998로 일치했다.


두 실수 모두 **실제로 쓰는 것과 다른 조건으로 검증한 것**이 원인이었다.

---

## 5. 기술 구조

---

### 5.1 전체 흐름



## 5.2 조항 분리

계약서 형식이 제각각이라 여기서 대부분의 실패가 나온다.

조 제목과 본문이 다른 줄에 있다. 실제 약관을 넣었더니 조항이 0개 잡혔다. 줄 단위로 나누면 제목 줄은 본문이 0자가 되고 본문 줄은 조 번호가 없어 버려진다. 조 번호로 시작하는 줄에서만 끊고 나머지는 앞 조항에 이어붙이도록 고쳤다.

호 번호 정규식에 마침표를 넣었다가 174개 중 20개만 잡았다. 마침표를 뺀 뒤 1,074개가 잡혔다.

파싱에 실패하면 억지로 쪼개지 않고 "분리 불가"로 표시한다. 잘못 나눈 조항은 이후 매칭 단계 전체를 오염시킨다. 표준약관 39건 중 34건 성공, 5건은 제N조 구조가 없는 지침·고시였다.

### 5.3 매칭 — 2단계

임베딩 모델은 jhgan/ko-sroberta-multitask 를 실측으로 골랐다. 후보였던 multilingual-e5-small 과 비교했을 때 관련·무관 유사도 간격이 0.0186 대 0.2613으로 14배 차이가 났다.

매칭 방식 네 가지를 라벨 55개로 비교했다.

| 방식                     | Top-1 | Top-3 |
|------------------------|-------|-------|
| A. 조별로 유형을 이어붙여 벡터 1개  | 65.5% | 94.5% |
| B. 유형별 벡터 + 조별 최대      | 70.9% | 87.3% |
| A로 후보 3개 → B로 재정렬 (채택) | 70.9% | 94.5% |
| 0.7A + 0.3B 가중합        | 72.7% | 94.5% |

A는 넓게 잘 잡고 B는 좁게 잘 고른다. 순서대로 쓰면 둘 다 얻는다. 가중합이 1건 더 맞췄지만 채택하지 않았다. 그 0.7은 표본 55개에서 고른 값이라 과적합 위험이 있고, 40 대 39는 통계적으로 같다. 자유 파라미터가 없는 쪽이 견고하다.

### 5.4 LLM은 찾는 데 쓰지 않는다

조항의 구조(누구의 무엇이 주어지는가)를 LLM으로 뽑아 매칭에 쓰려 했으나 실패했다 (Top-1 70.9% → 69.1%). 원인은 묻는 질문이 달랐다는 것이다. 매칭은 "무엇에 관한 조항인가"를 풀고 구조는 "누가 무엇을 잃는가"에 답한다. 표준약관은 심사를 거쳐 대부분 중립적이라 조항 85개 중 59개가 "주어지는 것 없음"으로 나왔고, 그것은 모델의 실패가 아니라 정확한 답이었다.

구조 추출의 제자리는 찾는 일이 아니라 찾은 뒤 보여주는 일이다.

5.5 스택

| 층     | 쓴 것                                  | 왜                                    |
|-------|--------------------------------------|--------------------------------------|
| 파이프라인 | LangGraph                            | 조항끼리 의존이 없어 조항별로 fan-out 하고 리듀서로 합친다 |
| 임베딩   | sentence-transformers / ONNX Runtime | 배포 시 ONNX로 바꾸면 메모리가 711MB → 272MB    |
| LLM   | OpenAI gpt-4o-mini                   | 구조 추출(선택 기능). <b>없어도 핵심 기능은 동작한다</b> |
| API   | FastAPI                              | 화면까지 함께 서빙해 터널 하나로 공개                |
| 화면    | React (Vite)                         | 원문과 조문을 좌우로 나란히 놓는 배치가 이 서비스의 전부     |
| 공개    | Cloudflare Quick Tunnel              | 계정·카드 없이 임시 주소                       |

6. 화면

지킨 것

경고색과 판정 어휘를 쓰지 않는다. 빨강·느낌표·신호등, "위험"·"불공정"·"무효" 같은 말을 넣지 않았다. **시각 언어가 텍스트보다 강하기 때문이다.** 고지에 "판정하지 않습니다"라고 아무리 적어도 화면이 빨강게 물들면 사용자는 판정으로 받아들인다.

**1·2·3순위를 같은 무게로 놓는다.** 1순위 정확도가 절반이 안 되므로 1순위만 크게 하면 사용자를 잘못 이끈다.

**내부 점수를 화면에 내지 않는다.** 0.4883 을 보면 "49% 위험"으로 읽힌다.

**조문 원문을 카드 전체 폭에 편다.** 좁은 칸에 넣었더니 한 글자씩 세로로 줄바꿈돼 읽을 수 없었다(폭 268px → 924px로 고침).

일반인을 위한 안내

법 조문을 그대로 보여주면 벽이다. "의사표시의 의제", "일정한 작위(作爲) 또는 부작위(不作爲)" 같은 말은 읽어도 뜻을 모른다. 세 가지를 붙였다.

- **조문마다 쉬운 안내 한 줄.** "~를 다루는 조문입니다"로 주제만 말하고 유불리는 판단하지 않는다
- **그 조문에 실제로 나오는 용어만 풀이**(사전 17개 중 해당하는 것만)
- **'무효' 배지 설명.** "법이 이런 내용의 조항을 무효로 정하고 있다는 뜻입니다. **지금 보고 계신 계약서 조항이 무효라는 뜻이 아닙니다.**"

마지막 것이 가장 오해하기 쉬운 지점이라 특별히 넣었다.

### 개인정보

**붙여넣은 약관은 저장하지 않는다.** 파일·DB에 쓰는 코드가 없고 서버 접근 로그에도 본문은 남지 않는다. 화면에서 그 사실을 밝힌다.

후기 게시판만 저장하며, **작성자 본인과 운영자만 읽을 수 있다.** 비밀번호는 pbkdf2로 해시해 보관하고, 틀렸을 때 "틀렸다"고 알리지 않고 빈 목록을 준다.

## 7. 검증과 개선

### 테스트 10개

성능이 아니라 **계약**을 잔다. 정확도는 평가 세트로 따로 잔다.

고친 것마다 회귀 테스트를 남겼다. 특히 이 둘이 중요하다.

- `test_no_confidence_label_leaks` — 없앤 확신도 표시가 되돌아오는 것을 막는다
- `test_title_and_body_on_separate_lines` — 실제 계약서 형식이 다시 깨지는 것을 막는다

### 실제로 써보고서야 드러난 것들

로컬 시험만으로는 못 찾았고, **실제 약관을 넣어보고서야 알았다.**

| 증상         | 원인                          |
|------------|-----------------------------|
| 조항 0개      | 조 제목과 본문이 다른 줄에 있는 형식을 못 읽음 |
| 조문이 세로로 놓림 | 좁은 칸에 넣어 한 글자씩 줄바꿈          |
| 목적 조항이 1순위 | 어느 약관에나 있고 늘 비슷하게 쓰여 점수가 뜸  |

## 8. 한계

정직하게 밝힌다. 이것을 감추면 이 프로젝트의 취지가 무너진다.

**실제 계약서에서 보여준 것 중 관련 있는 비율이 27%다.** 관련 없는 조항에도 후보가 붙는다. 네 갈래로 고치려 했으나 전부 실패했고, 조정의 문제가 아니라 방법의 한계로 보인다. 임베딩은 "계약 문장끼리 비슷하다"까지만 보고 특정 불공정 유형에 해당하는지는 보지 못한다.

**표본이 작다.** v2 85개, v3 41개다. 조문별로 쪼개면 더 작아진다. 수치에 신뢰구간을 함께 적은 것은 그 때문이다(v3 Top-3 75.0%, 95% 구간 47~91%).



**제7~14조만 다룬다.** 실제 분쟁이 많은 제3·5·6조는 대상이 아니다. 제6조는 일반원칙이라 거의 모든 조항에 걸쳐 후보로서 의미가 없다.

**정식 배포를 못 했다.** 임베딩 모델 때문에 실행 메모리가 649MB인데, 카드 등록 없이 그만큼을 무료로 주는 곳이 없었다(Render 512MB, HF Spaces는 Docker 유료, Railway-Fly.io는 무료 티어 폐지). ONNX로 바꿔 711MB에서 272MB까지 줄였고 성능은 그대로였다.

int8 양자화까지 하면 382MB로 무료 티어에 들어가지만 **Top-1이 70.9%에서 58.2%로 떨어져 쓰지 않았다.** 정확도를 팔아 배포를 사는 거래는 이 프로젝트의 우선순위 1번(정확성과 신뢰성)에 어긋난다. 지금은 Cloudflare Quick Tunnel로 임시 공개한다.

**후기 데이터가 아직 없다.** 지인 테스트를 준비했으나 이 문서 작성 시점에는 수집 전이다.

## 9. 실행 방법

파이썬 3.12, Node 20 이상. 윈도우 기준.

```
# 1. 설치
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt

# 2. 모델 준비 (처음 한 번, 441MB라 리포에 없음)
python src/build_onnx.py

# 3. API 서버
uvicorn src.api:app --port 8000

# 4. 화면
cd web && npm install && npm run dev

# 5. 테스트
python tests/test_api.py
```

지인에게 링크를 보내려면 `.\서비스_켜기.ps1` 하나로 서버와 터널이 함께 뜬다.

### 환경변수

| 이름             | 필요한 곳            | 없으면                |
|----------------|------------------|--------------------|
| LAW_OC         | 법령·판례 재수집        | 이미 받아 둔 data/ 로 충분 |
| OPENAI_API_KEY | 구조 추출(선택), 평가 도구 | 매칭과 화면은 그대로 동작     |
| ADMIN_KEY      | 후기 전체 보기         | 운영자 보기만 막힘         |

## 성능 재측정

```
python src/score_eval_v2.py    # 표준약관 85개
python src/score_eval_v3.py    # 판례 인용 조항 41개
```

## 10. 만들면서 배운 것

측정 대상을 잘못 고르면 아무리 정교하게 재도 소용없다. 평가 세트 v1은 이 서비스가 하지 않는 일(불공정 판정)을 재려 해서 실패했다.

쉬운 표본으로 켄 수치는 실사용을 대표하지 않는다. 표준약관에서 97.9%였던 것이 실제 계약서에서 25%였다. v3를 만들지 않았다면 몰랐을 것이다.

검증 조건은 실제 사용 조건과 같아야 한다. 짧은 문장 3개로 "동일하다"고 판단한 것, 법 조문 원문을 쿼리로 넣고 "문체 효과"라고 읽은 것 모두 여기서 나온 실수다.

성능을 못 올리면 약속을 바꾼다. 확신도를 표시할 근거가 없으면 표시를 없애는 것이 사용자에게 정직하다.

## 부록 · 출처

- 법령·판례 데이터: **법제처 국가법령정보 공동활용** ([open.law.go.kr](http://open.law.go.kr))
- 임베딩 모델: `jhgan/ko-sroberta-multitask` (Hugging Face)
- 이 문서의 모든 수치는 저장소의 평가 스크립트로 재현할 수 있다